



Rapport de projet 4A :

Prédiction de séries temporelles à l'aide de réseaux de neurones : application à la finance

Léa DERVIEUX & Maxime BRÉE
Élèves en 4ème année
Département IMDS

Thierry CHATEAU
Responsable de projet

Soutenu le 11 février 2026

Résumé

La prédiction de séries temporelles financières est un problème complexe en raison de la forte volatilité et de l'incertitude inhérente aux marchés. Les approches classiques, telles que les réseaux de neurones récurrents, produisent généralement des prévisions déterministes et peinent à modéliser la distribution des valeurs futures.

Ce projet explore l'utilisation des modèles de diffusion pour la prédiction d'indicateurs boursiers à partir de séries temporelles financières. Plusieurs architectures préexistantes ont été étudiées, notamment Kronos et TimeDiffusion, qui se sont révélées limitées dans ce contexte. Finalement, le modèle TimeGrad a permis d'obtenir des résultats intéressants, capables de générer des trajectoires futures réalistes conditionnées par les valeurs passées.

Les résultats montrent que les modèles de diffusion, lorsqu'ils sont correctement adaptés aux séries temporelles financières, constituent une approche prometteuse pour la modélisation des tendances d'indicateurs des marchés financiers.

Mots clés

Machine Learning, séries temporelles financières, modèle de diffusion, TimeGrad, indicateurs boursiers, prédictions, stochastiques.

Remerciements

Nous souhaitons remercier tout particulièrement Thierry Chateau et Arnaud Vaissaire pour leur disponibilité, leur patience, leur passion et leurs précieux conseils tout au long de ce projet. Leur accompagnement constant a été d'une aide déterminante, et ce travail n'aurait pu aboutir sans leur soutien.

Nous exprimons également notre gratitude envers le département IMDS pour l'équipement informatique mis à disposition, nous ayant permis la réalisation de ce projet.

Résumé.....	1
Mots clés.....	1
Remerciements.....	1
Table des figures.....	3
Introduction.....	4
A- Contexte.....	4
B- Cadre du projet.....	4
1. Etat de l'art.....	6
1.1 Indicateurs boursiers utilisés.....	6
1.2 Les stochastiques.....	7
1.3 Prédiction de séries temporelles financières.....	8
1.4 Modèles de diffusion.....	9
1.5 Travaux existants sur les modèles de diffusion adaptés aux séries temporelles.....	10
2. Parcours.....	11
2.1. Modèle Kronos.....	11
2.1.1 Architecture du modèle.....	11
2.1.2 Données et protocole expérimental.....	12
2.1.3 Résultats et limites.....	12
2.2. Modèle TimeDiffusion.....	13
2.2.1 Présentation du modèle.....	13
2.2.2 Difficultés rencontrées et résultats.....	15
2.3. Modèle de Cédric Chauvière.....	15
2.3.1 Première approche.....	15
2.3.1 Conclusions du modèle.....	16
3. Modèle final - TimeGrad.....	17
3.1. Architecture, data et entraînement.....	17
3.1.1. Data, prédictions et post traitement.....	17
3.1.2. Récupération des données.....	19
3.1.3. Métriques utilisées.....	20
3.1.4. Sortie du modèle.....	20
3.2 Résultats.....	21
3.2.1. Choix des hyperparamètres.....	21
3.2.1.1. Structure, largeur et profondeur.....	21
3.2.1.2. Epochs et batch size.....	22
3.2.2. Métriques.....	23
3.2.3. Analyse des résultats.....	26
4. Difficultés rencontrées et perspectives d'évolution.....	28
Conclusion.....	30
Bibliographie.....	32

Table des figures

Figure 1 : *Schéma d'un Réseau de diffusion*

Figure 2 : *Principe de la Tokenisation*

Figure 3 : *Architecture TimeDiffusion*

Figure 4 : *Exemple de courbe prédictive et intervalles de confiance générées*

Figure 5 : *En-têtes et premières valeurs de l'excel prédictions*

Figure 6 : *Courbes de train loss et de validation loss*

Figure 7 : *Extrait des résultats des métriques sur Excel*

Figure 8 : *Résultat des tests de corrélation*

Figure 9 : *Graphique de 5 prédictions de Stoch %D sur des fenêtres temporelles entrecoupées*

Introduction

A- Contexte

La prédiction des séries temporelles constitue un défi majeur en raison de la nature intrinsèquement stochastique et volatile des marchés. Certaines méthodes telles que les réseaux de neurones récurrents (LSTM, GRU) ont longtemps été privilégiés, ils se limitent souvent à des prédictions déterministes ne modélisant pas l'incertitude inhérente aux cours boursiers.

Récemment, les modèles de diffusion ont émergé comme des techniques puissantes de génération de données, initialement appliquées à des images ou à des signaux audios. Les modèles adaptés aux séries temporelles financières restent encore peu explorés, de par leur nature plus générative que prédictive, nous y reviendrons plus tard.

Ce projet s'inscrit dans la continuité de projets précédents et se concentre sur l'application de modèles de diffusion dans le cadre de la prédiction d'indicateurs boursiers. L'objectif de ce travail est d'utiliser un modèle de diffusion et d'en étudier la pertinence et les limites, pouvant nous offrir ou non une estimation des intervalles de confiance et une vision plus probabiliste des tendances du marché.

Au cours de ce projet, plusieurs architectures / projets ont été étudiées, notamment Kronos, et de nombreux modèles disponibles sur GitHub, avant d'aboutir à un environnement de travail capable de générer des trajectoires stochastiques réalistes pour des séries temporelles financières.

B- Cadre du projet

Ce projet est la pièce maîtresse de notre quatrième année en école d'ingénieur à Polytech Clermont et nous offre l'opportunité de nous plonger dans le monde du machine learning d'une façon on ne peut plus concrète. Commencé en début d'année scolaire 2025, l'échéance se place au rendu et à la soutenance de ce projet, le mercredi 11 février 2026. Tout au long de la réalisation, des réunions hebdomadaires ont été organisées avec Thierry Château, enseignant-chercheur et tuteur, et Arnaud Vaissaire, intervenant extérieur et entrepreneur. Leur double

expertise a été déterminante afin d'assurer le suivi de notre travail, pour orienter nos choix méthodologiques et ajuster les expérimentations. Nous avons donc commencé cette aventure par une veille technique nécessaire, tant le monde du machine learning évolue rapidement.

1. Etat de l'art

1.1 Indicateurs boursiers utilisés

Les indicateurs boursiers sont des outils largement utilisés en finance pour analyser l'évolution des marchés et aider à la prise de décision. Ils sont généralement calculés à partir des valeurs des prix, des volumes ou des rendements sous forme de séries temporelles et visent à mettre en évidence des tendances, des signes de retournement ou des niveaux de volatilité.

On distingue principalement trois grandes catégories d'indicateurs :

- Les indicateurs de tendance, qui permettent d'identifier la direction générale du marché sur une période donnée, tels que les moyennes mobiles simples (SMA) ou exponentielles (EMA) ;
- Les indicateurs de momentum, qui mesurent la vitesse et l'intensité des variations des prix. Parmi ceux-ci figurent les stochastiques %K et %D, ainsi que le Relative Level (RL), (que nous utiliserons dans notre analyse) qui indiquent respectivement la position relative du prix actuel par rapport à son intervalle de variation récent et fournissent des signaux de surachat ou de survente ;
- Les indicateurs de volatilité, qui mesurent l'amplitude des fluctuations des prix sur une période donnée, comme l'Average True Range (ATR).

La prédiction d'indicateurs boursiers à partir de séries temporelles pose ainsi des défis importants. La nature stochastique et bruitée de certains indicateurs rend nécessaire l'utilisation de modèles capables de capturer la variabilité et l'incertitude du marché, ce qui a conduit au développement des modèles statistiques et neuronaux, présentés dans la section suivante.

1.2 Les stochastiques

On distingue deux grandes familles de processus stochastiques :

- Processus à temps discret : l'évolution se fait par étapes distinctes. L'état futur dépend uniquement de l'état actuel, comme pour les chaînes de Markov ou les marches aléatoires.
- Processus à temps continu : la variable évolue de manière continue dans le temps. Le mouvement brownien en est un exemple classique, modélisant le mouvement chaotique de particules. En finance, il est utilisé pour représenter l'évolution des prix, car il combine une tendance déterministe (la dérive) et une composante aléatoire (la volatilité). Les processus de diffusion sont une généralisation du mouvement brownien, permettant de modéliser des trajectoires continues influencées par le hasard et par des tendances structurelles.

Dans l'analyse technique, les stochastiques financières sont des indicateurs dérivés qui mesurent la position d'un prix par rapport à ses extrêmes récents.

Ces indicateurs permettent d'anticiper la tendance et la volatilité d'un actif, en reliant les mouvements observés aux processus stochastiques sous-jacents. Par exemple, si le prix atteint les extrêmes récents de manière répétée, les stochastiques signalent une surachat ou une survente, en reflétant l'effet du terme aléatoire du processus de diffusion.

La compréhension des stochastiques dans le contexte des processus stochastiques est essentielle pour :

- Interpréter correctement les signaux d'achat/vente.
- Relier les modèles théoriques (mouvement brownien, diffusion) aux indicateurs observables (%K, %D, RL).
- Évaluer la précision des modèles prédictifs, notamment lorsqu'ils génèrent des trajectoires stochastiques simulées pour les séries temporelles financières.

En combinant ces notions, il est possible de développer des modèles capables de prévoir non seulement les valeurs futures des cours, mais aussi la distribution probabiliste de ces valeurs et les tendances potentielles, offrant ainsi une meilleure compréhension de l'incertitude du marché.

1.3 Prédiction de séries temporelles financières

La prédiction des séries temporelles est un problème étudié tout particulièrement en finance puisqu'elle a pour but d'anticiper l'évolution des prix, des rendements ou d'indicateurs techniques.

Avec l'essor du deep learning, des modèles neuronaux comme les réseaux de neurones récurrents (RNN), et en particulier les LSTM (Long Short Term Memory) et GRU (Gated Recurrent Unit), ont émergé, fin des années 90 pour les LSTM et années 2010 pour les GRU. Ces architectures permettent de modéliser des dépendances temporelles à long terme et ont montré de meilleures performances que les approches statistiques classiques. Cependant, ces modèles produisent généralement des prédictions déterministes, fournissant des valeurs uniques pour chaque horizon temporel, à chaque prédiction.

D'autres proposent des modèles hybrides, combinant alors différentes architectures neuronales afin d'exploiter leurs avantages respectifs. Parmi ces approches, les modèles combinant réseaux convolutionnels (CNN, années 90-2000) et réseaux récurrents de type LSTM ont suscité un intérêt particulier par la communauté dans la prédiction de séries temporelles. En effet les CNN sont particulièrement efficaces dans l'apprentissage de patterns, à comprendre l'apprentissage de comportements redondants des données, de manière locale et à court terme en exploitant des filtres convolutifs sur les dataset, alors multivariés (entrée de plusieurs éléments en une fois dans le modèle, et non une série unique).

Dans le contexte financier, ils permettent notamment de détecter des variations cycliques, rapides, ou des structures locales présentes sur les prix ou indicateurs.

En combinant un CNN en amont d'un LSTM, ces modèles hybrides permettent d'extraire automatiquement des représentations pertinentes de ces schémas globaux. Les architectures CNN-LSTM ont montré des performances améliorées par

rapport aux modèles classiques dans plusieurs tâches de prédictions. Toutefois, malgré ces améliorations, ces modèles restent encore majoritairement déterministes.

1.4 Modèles de diffusion

Les modèles de diffusion constituent une classe récente de modèles génératifs probabilistes, apparus en 2015, reposant sur un processus biphasé : une phase de diffusion où du bruit (gaussien généralement) est progressivement ajouté aux données, et une phase inverse où un réseau de neurones apprend à retirer ce bruit étape par étape. Ces modèles ont démontré une performance remarquable dans la génération d'image, d'audio et de données synthétiques, en particulier grâce à leur capacité à approximer des distributions complexes.




Figure 1 : Schéma d'un Réseau de diffusion

Malgré leur succès dans ces domaines, l'application des modèles de diffusion aux séries temporelles reste encore peu explorée, en effet s'ils sont excellents pour la génération, la prédiction d'une série repose sur d'autres principes, tels que la succession cohérente des valeurs et la prise en compte du passé : ce qu'on appelle conditionnalité. Les architectures initialement proposées sont majoritairement conçues pour des données spatiales (images), utilisant (entre autres) des réseaux convolutionnels là où les séries temporelles financières présentent des caractéristiques spécifiques, telles que la non-stationnarité, la forte volatilité et le bruit, qui compliquent l'apprentissage du processus inverse de diffusion.

1.5 Travaux existants sur les modèles de diffusion adaptés aux séries temporelles

Plusieurs travaux récents ont tenté d'adapter les modèles de diffusion aux séries temporelles. Des architectures spécifiques, telles que Kronos, ont été proposées pour la modélisation de données séquentielles. Cependant, ces modèles restent expérimentaux et leur application aux données financières demeure limitée.

Dans notre étude, l'analyse de Kronos et de plusieurs implémentations open-source disponibles sur GitHub ne nous ont permis d'obtenir que peu de résultats satisfaisants. Ceci est notamment dû à des difficultés de convergence des modèles et à une mauvaise adaptation aux propriétés des séries financières, i.e. un modèle non adapté aux objets étudiés.

Ces limitations soulignent le manque de modèles de diffusion robustes adaptés à la prédiction de séries temporelles financières, et motivent la recherche de nouvelles architectures ou adaptations spécifiques capables de produire des prévisions stochastiques réalistes. De plus les modèles de diffusions requièrent de larges dataset afin de mener à bien l'apprentissage et de grandes tailles de réseaux neuronaux, pour exemple :

- DALL-E 2, un modèle de diffusion conditionnelle développé par Open AI, possède plus de 3 milliards de paramètres, mais s'applique pour la génération de multiples images à partir de textes.
- MidJourney, un modèle de diffusion multimodale de MidJourney Inc., possède plus de 5 milliards estimés de paramètres pour la production de contenus visuels haut de gamme et hautement réalistes.

Bien que les modèles de génération d'images soient extrêmement denses, la prédiction de séries temporelles à horizon court ($T+15$) permet l'usage d'architectures plus légères. La génération d'images vise à produire des images de grande qualité (disons 1080p de résolution minimum) soit plus de 2 millions de pixels à générer de manière cohérente, expliquant la profondeur et l'étendue des modèles cités ci-dessus. Dans notre cas, nous ne souhaitons prédire qu'à $T+15$, soit 15 intervalles de temps au-delà du contexte donné. Les dimensions du modèle recherché seront bien moindres et directement impactées par le nombre de variables (features) passées en entrée du modèle (environ 100 000 paramètres se révéleront suffisants).

Malgré tout, la question de la taille du jeu de données reste centrale et nous y reviendrons lors de l'étude de notre modèle de travail : TimeGrad.

2. Parcours

2.1. Modèle Kronos


Comme conseillé par notre tuteur, nous avons étudié et implémenté le modèle Kronos dans un premier temps afin de nous donner un regard plus critique sur ce que nous verrons ensuite. Il s'agit d'un modèle spécifiquement pré-entraîné pour la prédiction de séries temporelles financières. Ce modèle est plus facile à comprendre et ne se base pas sur de la diffusion. Kronos se distingue des approches classiques mais reste biphasé. En effet, il se munit d'un tokenizer spécialisé qui convertit les données en tokens discrets avant d'utiliser un Transformer autorégressif à décodeur uniquement. Le choix d'utiliser des tokens vient du fait qu'un Transformer ne sait pas manipuler de valeurs continues. Le processus de normalisation repose sur plusieurs étapes : les séries financières sont d'abord normalisées, puis quantifiées en niveaux discrets, avant d'être encodées sous forme binaire (bits). La conversion en bits permet une stabilité numérique et une représentation plus compacte des valeurs, plus adaptée aux séries financières fortement bruitées.

2.1.1 Architecture du modèle

Kronos repose sur une architecture Transformer similaire à celle des modèles de langage (type GPT). C'est un modèle neuronal conçu pour traiter des séquences de données en exploitant des mécanismes d'attention. Contrairement aux réseaux récurrents, il ne traite pas les données de manière séquentielle, mais considère l'ensemble de la séquence simultanément. Chaque élément peut ainsi prêter attention aux autres, ce qui permet de capturer efficacement des dépendances à long terme. Dans un cadre autorégressif, le modèle apprend à prédire l'élément suivant de la séquence à partir des éléments passés.

Notre Transformer comprend :

- Mécanismes de self-attention permettant de capturer les dépendances à long terme dans les séries temporelles,
- Couches entièrement connectées (feed-forward),
- Encodages positionnels pour conserver l'ordre temporel des données tokenisées.



Contrairement aux modèles de séries temporelles à usage général, Kronos est spécialement conçu pour gérer les caractéristiques hautement bruitées et multi-dimensionnelles des données financières. Son tokenizer transforme les données continues en représentation discrète, permettant au Transformer de traiter les marchés financiers comme un « langage » à part entière.

Figure 2 : Principe de la Tokenisation

2.1.2 Données et protocole expérimental

Les données utilisées proviennent d'une clé API fournie par notre tuteur de projet et correspondent à des séries temporelles financières réelles. Les séries ont été injectées dans le modèle Kronos conformément aux recommandations de l'implémentation officielle.

Afin d'évaluer les performances du modèle, nous avons utilisé une mesure d'accuracy sur la prédiction de la tendance, consistant à comparer la direction prédite du close (hausse ou baisse) à la direction du marché sur un horizon donné.

2.1.3 Résultats et limites

Bien que le modèle Kronos ait pu être entraîné et exécuté correctement, les résultats obtenus se sont révélés atypiques. Nous avons effectué plusieurs tests qui nous amènent tous à la même conclusion : les tickers sont très corrélés et la précision est assez hasardeuse. Par exemple, sur un échantillon de 100 tickers aléatoires, avec un intervalle de 15 minutes et un historique de 485 données et une prédiction portant sur 15 valeurs futures. Nous obtenons une précision globale de 42,42%.

Cette première performance est inférieure au hasard, ce qui suggère que le modèle n'apporte pas de valeur prédictive significative pour cette tâche spécifique et dans cette configuration.

Sur les mêmes paramètres mais avec un intervalle de 1 jour, on observe une précision de 52%.

Plusieurs facteurs peuvent l'expliquer. Kronos a été pré-entraîné et évalué sur des métriques comme l'erreur absolue moyenne (MAE), qui mesure l'amplitude moyenne des erreurs entre valeurs prédites et valeurs réelles. Une accuracy de 42% ne signifie pas nécessairement que des prédictions de prix sont mauvaises en valeur absolue, puisqu'elle ne tient pas compte de l'amplitude de l'erreur, ni de la proximité entre la valeur prédite et la valeur réelle.

Après l'étude de Kronos, il est apparu que, malgré son architecture avancée et sa capacité à traiter des séries financières multi-dimensionnelles, le modèle ne produisait pas de prédictions stables ni temporellement cohérentes. Cette limite nous a conduit à explorer des modèles de diffusion capables de générer des valeurs stochastiques, avec l'espoir d'obtenir des trajectoires plus représentatives des dynamiques réelles des marchés.

2.2. Modèle TimeDiffusion

2.2.1 Présentation du modèle

TimeDiffusion est donc le premier modèle de diffusion que nous avons testé. Cependant, ce modèle ne prend pas de données multivariées, ce qui ne nous permet pas d'avoir de résultats intéressants dans notre cadre. En effet de nombreux travaux ont déjà étudié la prédiction de cours boursiers en prenant les données brutes seulement, telles que le close d'un cours. Nous parlons depuis le début des difficultés d'étude de ces cours, et de l'intérêt d'étudier des indicateurs plutôt que le cours directement. L'univarié n'est donc pas un prisme intéressant pour notre étude. Ce modèle est conçu pour traiter directement des séries temporelles en exploitant des techniques modernes d'apprentissage profond, combinant processus de diffusion, convolutions dilatées, connexions résiduelles et, dans certaines variantes, des mécanismes d'attention.




Figure 3 : Architecture TimeDiffusion

L'objectif déclaré de TimeDiffusion est de permettre des prévisions, de l'imputation et de la génération de séries temporelles à partir d'une seule séquence d'entrée sans nécessiter de grands jeux de données externes, en s'inspirant des approches classiques auto-régressives tout en incorporant des étapes de bruitage et de débruitage pour apprendre la structure des données.

Dans l'implémentation principale, le modèle prend en entrée une série temporelle de forme [canaux, longueur] et propose des méthodes pour :

- faire des prévisions jusqu'à un certain horizon ;
- générer des séries synthétiques proches des données observées ;
- imputer des valeurs manquantes dans des séries incomplètes.

La philosophie sous-jacente de TimeDiffusion est d'entraîner le modèle uniquement sur la série fournie sans recourir à de nombreux exemples, ce qui vise à s'adapter à des contextes où les données disponibles sont limitées, comme c'est souvent le cas en finance.

2.2.2 Difficultés rencontrées et résultats

Malgré une mise en œuvre technique fonctionnelle, notre expérimentation avec TimeDiffusion n'a pas permis d'obtenir des résultats convaincants pour la prédiction stochastique de séries financières. Lors de plusieurs sessions d'entraînement, nous avons observé que le modèle produisait des prévisions très constantes, manquant de diversité probabiliste, similaires quelles que soient les exécutions, sans réelle variabilité ni diversité dans les trajectoires générées : une stabilité excessive pour notre sujet d'étude. Cela signifie que le modèle se comportait davantage comme une fonction de régression standard que comme un modèle génératif stochastique, ce qui ne répondait pas aux objectifs principaux de notre projet, qui visaient à capturer la distribution des valeurs futures plutôt que des points fixes.

Le modèle TimeDiffusion, bien qu'étant un modèle de diffusion classique, présentait des contraintes importantes : il ne permettait pas d'exploiter des données multivariées, ce qui limitait la qualité et la pertinence des prévisions. Pour pallier ces limitations, nous avons étudié le modèle de M. Chauvière, conçu pour traiter des séries multivariées et permettant une approche plus flexible et modulable des prévisions stochastiques.

2.3. Modèle de Cédric Chauvière

2.3.1 Première approche

Nous avons ensuite exploité un nouveau modèle de diffusion permettant l'utilisation de données multi-variées pour la prédiction, fourni par M. Chauvière, directeur des études à Polytech Clermont. Celui-ci, implémente de manière procédurale et non sous forme de classes, s'est révélé plus simple à comprendre, à modifier et à manipuler lors des phases d'expérimentation. Son fonctionnement peut être décomposé en plusieurs étapes distinctes :

- Chargement et préparation des données,
- Processus de bruitage progressif des séries,
- Création et entraînement du modèle,

- Génération de nouveaux échantillons suivie des étapes de bruitage puis débruitage,
- Visualisation des prédictions obtenues.

2.3.1 Conclusions du modèle

Malgré une mise en œuvre fonctionnelle, ce modèle n'a pas permis d'obtenir des résultats satisfaisants dans le cadre de la prédiction de séries temporelles financières. En effet, il a été conçu pour des séries dans lesquelles la dimension temporelle n'influence pas les valeurs futures. Le modèle fonctionne de manière indépendante pour chaque point, sans prendre en compte les valeurs précédentes de la série.

Ainsi, le modèle apprend principalement la distribution globale des données, sans modéliser les dépendances temporelles. Cela conduit à la génération de points individuellement cohérents en termes de valeurs, mais incohérents du point de vue temporel, ce qui limite fortement son intérêt pour la prédiction financière.

Dans ce contexte, l'utilisation d'un modèle conditionnel, mal conditionné pour notre dessein, intégrant explicitement les valeurs passées pour prédire les valeurs futures mais dans un ordre non déterminé ne s'est pas révélé adapté à notre problématique. Suite à un échange avec M. Chauvière, nous avons testé le code fourni ainsi que le fichier de données transmis. Toutefois, malgré ces essais, nous n'avons pas réussi à produire un graphique permettant de comparer directement les données générées par le modèle aux données réelles, ce qui a limité l'analyse des résultats.

Les modèles précédemment testés ont permis de mieux comprendre les contraintes et les besoins spécifiques à la prédiction stochastique des séries financières. Forts de ces enseignements, nous avons un cahier des charges précis du modèle final souhaité : un modèle multivarié, non déterministe (stochastique), conditionné temporellement. Suite à ces exigences, nous avons sélectionné le modèle suivant : TimeGrad.

3. Modèle final - TimeGrad

3.1. Architecture, data et entraînement

Après étude de différents modèles, TimeGrad s'est révélé comme l'architecture de référence pour notre étude. Il s'agit d'un modèle centré sur la prédiction de séries temporelles par diffusion, conditionnel, prenant en compte un contexte de dimension $N \times \text{CONTEXT_LENGTH}$ en entrée et renvoyant des prédictions de dimensions $N \times \text{PREDICTION_LENGTH}$. L'entraînement se passe de la manière suivante :

- il parcourt le dataset d'entraînement de manière séquentielle en commençant par les premières datas
- il prend le contexte en entrée et génère une prédiction
- il compare cette prédiction à la réalité (connue donc)
- il ajuste ses paramètres par minimisation d'une fonction de perte (loss function)
- Il réitère ce processus sur un nombre défini de lots (batches) par époque, permettant un échantillonnage représentatif du dataset.

Lors de l'entraînement à chaque epoch est lancée une epoch de test sur le dataset de test afin d'observer et étudier l'évolution de la loss. Nous avons ajouté le tracé d'une courbe afin de représenter

Tous nos hyper paramètres sont gérés par des variables définies au début du code ou dans le TimeGradEstimator de PyTorchTS. Nous discuterons ces hyper paramètres plus tard, dans la section résultats.

3.1.1. Data, prédictions et post traitement

Le dataset est extrait d'un excel fourni par M. Chateau et M. Vaissaire, regroupant près de 300 000 unités temporelles consécutives d'informations sur les open, high, low et close du cours du Bitcoin (BTC), après lecture du fichier par la bibliothèque Pandas, nos data sont transformées en ListDataset de la librairie

Gluonts (séries univariées), fusionnées à l'aide du MultivariateGrouper de Gluonts en une matrice du format acceptable : (longueur du dataset, nombre de features). Cette contrainte de changements de format provient d'une standardisation des entrées du modèle. On peut désormais le diviser à souhait pour isoler le dataset de test de celui d'entraînement.

Lors de la phase de prédiction chaque prédiction est "unique" dans le sens où il s'agit d'une sortie probabiliste, chacune correspondant à une possibilité. Afin de représenter le meilleur résultat nous effectuons plusieurs prédictions que nous affichons par quantiles afin de générer un intervalle de confiance - ici à 50 et 80% - des résultats, superposés aux vraies valeurs :




Figure 4 : Exemple de courbe prédictive et intervalles de confiance générées

Ici sur un contexte de 180 data et une prédiction de 30 unités temporelles. Représentation du close uniquement ici. Voici le genre de graphiques que nous souhaitons obtenir : des trajectoires probables à un certain niveau de confiance en gardant un aperçu de la vérité.

3.1.2. Récupération des données

Pour ce type de prédiction, le jeu de données doit être très large, et se compte en milliers de données. Le dataset sur lequel nous travaillons a pour colonnes les suivantes : “index” (simple index croissant des données, la première unité temporelle étant indexée à un), “open”, “high”, “low”, “close”, et de quelques stochastiques (RL, %D, et %K).

Voici la formule des stochastiques utilisées :

$$RL = \frac{C_t - L_n}{H_n - L_n}$$

Avec C le ‘Close’ au temps t, n la période choisie (pour nous n=15), L le cours du ‘Close’ le plus bas sur la période n et H le cours du ‘Close’ le plus haut sur la période n. Si on a un dénominateur égal à 0, la fonction retourne alors 0.

On a ensuite :

$$\%K = 100 \times RL$$

Et enfin :

$$\%D = MMS_3(\%K)$$

avec %D la moyenne mobile simple de %K calculée sur une fenêtre de trois périodes.

Ces indicateurs stochastiques sont fournis dans le fichier Excel et ont servi de base à nos expérimentations de prédiction. Bien que nous ayons également tenté de recalculer ces stochastiques nous-mêmes à partir des formules théoriques, nous avons privilégié les valeurs déjà présentes dans le jeu de données. En effet, reproduire exactement les paramètres de calcul utilisés (fenêtres, conventions de lissage, gestion des cas limites) s’est avéré complexe, et de légères différences de paramétrage peuvent conduire à des valeurs difficilement comparables et donc moins exploitables pour l’apprentissage des modèles.

3.1.3. Métriques utilisées

Pour l'évaluation du modèle, nous avons utilisé plusieurs métriques différentes calculées sur 15 prédictions consécutives pour chaque stochastique :

- La tendance globale, qui va comparer la hausse ou la baisse de la courbe prédite avec celle de la courbe réelle. La performance est exprimée en pourcentage de tendance correctement prédite.
- La tendance locale entre deux points consécutifs, qui va être calculée de la même façon que la tendance globale.

$$Tendance(t) = \frac{1}{H} \sum_{j=1}^H Indicatrice(sign(x_{t+j} - x_t)) \text{ avec } H=15 \text{ dans notre cas.}$$

- Le coefficient de Pearson, qui évalue la corrélation entre les valeurs réelles et les valeurs prédites, qui va nous indiquer la relation entre les valeurs prédites

et réelles, calculée de cette manière :

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

$$\text{avec } \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \text{ la moyenne d'une variable.}$$

Cette approche permet d'évaluer à la fois la cohérence globale et la fidélité aux variations locales des séries temporelles.

3.1.4. Sortie du modèle

Afin d'obtenir une large dataset de résultats à analyser nous avons choisi de préserver les 5 000 points du dataset pour effectuer des prédictions puis des statistiques dessus. En sortie nous obtenons 5 000 prédictions sur nos 4 variables : Close, Stoch RL, Stoch %D et Stoch %K, de T0 la dernière valeur connue à T+15, dernière valeur prédite.

Chaque ligne contient donc la prédiction à t jusqu'à $t+15$ des valeurs réelles suivantes, correspondant à la colonne de la valeur réelle $i+1$ jusqu'à $i+16$ dans l'Excel, i étant la ligne de T_0 , voici une capture de ce document :

	A	B	C	D	E	F	G	H	I	J	K
1	index	open	high	low	close	stoch RL	stoch %D	stoch %K	close_pred_1	close_pred_2	close_pred_3
2	292848	96885,03	96926,78	96800,01	96807,99	27,40556	42,85384	27,86549	98545,05469	98524,38281	98432,35938
3	292849	96812,61	96834,08	96514,61	96730,59	31,51199	40,30988	29,90521	98346,625	98240,74219	98183,6875
4	292850	96727,3	96809,32	96540,94	96556,45	6,104554	37,99619	29,79189	97996,89844	98075,29688	98253,74219
5	292851	96556,72	96569,77	96225,93	96333,1	11,00229	35,9453	29,77334	98149,6875	98101,96094	98147,23438

Figure 5 : En-têtes et premières valeurs de l'excel prédictions

En vert les données d'entrée et en rouge les prédictions, facilitant l'analyse et la représentation de chaque prédiction pour un T_0 donné tout en pouvant vérifier aisément avec la réalité (prédiction du close en jaune essayant de prédire la valeur du close en bleu).

3.2 Résultats

3.2.1. Choix des hyperparamètres

Les hyperparamètres sont les éléments centraux que l'on peut modifier afin d'ajuster le modèle et son entraînement. Il n'existe pas de règle absolue quant au choix des hyperparamètres en machine learning, ainsi nous testons des valeurs crédibles, étudions le résultat et ajustons les valeurs pour les tests suivants.

3.2.1.1. Structure, largeur et profondeur

La dimension du réseau est au cœur de cet arbitrage. Une largeur excessive (ex: 256 neurones par couche) permet de capturer des motifs complexes, mais au risque d'un sur apprentissage (overfitting) où le modèle mémorise le bruit des données historiques plutôt que leur distribution sous-jacente. Par ailleurs, un réseau plus large allonge significativement le temps de convergence de l'entraînement, l'espace de recherche des paramètres optimaux devenant plus vaste. À l'inverse, une architecture trop restreinte (ex: 16 neurones) converge rapidement mais manque de "mémoire" pour traiter l'intégralité du contexte, risquant ainsi de négliger des corrélations subtiles entre les indicateurs stochastiques.

De la même manière, la profondeur influe sur la capacité d'abstraction du réseau. Si une structure trop "plate" peine à croiser les informations, un modèle trop profond peut souffrir d'une instabilité des gradients et d'une lourdeur calculatoire sans gain de précision notable.

Tableau comparatif d'erreurs en fonction du nombre de neurones par couche, pour trois couches, moyenne des valeurs sur cinq prédictions de contextes consécutifs :

Nombre de neurones	NRMSE	ND
16	0,4585	0,0064
128	0,3856	0,0042
256	8,3654	0,0039

Les métriques choisies ici pour comparer sont l'erreur des moindres carrés normalisée (NRMSE) et la déviation normalisée (ND), étant calculées avec la formule

suivante :
$$ND = \frac{\sum |y_{prédit} - y_{réel}|}{\sum |y_{réels}|}$$

En conclusion de nos tests, la configuration de 3 couches et de 128 neurones s'est imposée comme le point d'équilibre optimal : elle offre une expressivité suffisante pour traiter nos variables d'entrée tout en garantissant une convergence stable et un temps d'entraînement performant.

3.2.1.2. Epochs et batch size

Le dimensionnement de l'entraînement repose sur deux leviers temporels : la taille des lots (batch size) et le nombre d'itérations (epochs).

Nous avons fixé le batch size à 128, un compromis permettant de stabiliser le gradient de la fonction de perte tout en optimisant la mémoire vive du GPU, nous permettant d'utiliser au maximum les performances de notre machine : le goulot d'étranglement est le GPU. Concernant la durée de l'entraînement, nous avons, après tests, opté pour 12 epochs. Ce choix n'est pas arbitraire : il résulte d'une

observation attentive des courbes de loss d'entraînement et de validation, telles que la suivante :




Figure 6 : Courbes de train loss et de validation loss

En effet, au-delà de 10/12 epochs, bien que la perte sur le jeu d'entraînement continue de décroître, la perte de validation (calculée sur des données non vues) commence à stagner, voire à remonter. Ce point de divergence marque le début du surapprentissage, où le modèle délaisse la loi générale pour se spécialiser sur les bruits du dataset source. En stoppant l'entraînement prématurément, nous garantissons la robustesse des prédictions futures.

3.2.2. Métriques

Pour analyser ces prédictions, nous avons créé un Excel contenant la corrélation, la tendance point par point ainsi que la tendance sur 15 points, et ce pour chaque variables (Stoch %RL, Stoch %D, Stoch %K, et Close). Elles sont présentées comme ceci :

stoch %D_corr	stoch %D_tendance_15pts	stoch %D_tendance_pts_par_pts
0,059508265	1	3
0,403468744	1	5
0,642371112	1	5
0,637638558	1	4
0,634166887	1	5
0,596877951	1	5
0,700458412	1	6
0,542669632	1	8
0,364035939	1	8
-0,044694548	1	4
0,067733235	0	6

Figure 7 : Extrait des résultats des métriques sur Excel

Nous avons la corrélation, la tendance sur 15 points pour chaque ligne (égale à 1 si elle est correcte, 0 sinon), et enfin la tendance point par point, qui indique le nombre de points corrects par ligne.

Les résultats en ce qui concerne la corrélation sont assez peu concluants :




Figure 8 : Résultat des tests de corrélations

La distribution des corrélations entre valeurs réelles et prédictions pour une variable donnée est une estimation de la densité de corrélation sur toutes les lignes du Excel. Chaque point de la distribution correspond à la corrélation entre les 15 valeurs réelles suivantes et les 15 valeurs prédites pour une ligne donnée. Ensuite, on regarde toutes ces corrélations pour toutes les lignes et on trace la distribution.

Les trois stochastiques (%K, %D, RL) sont calculés à partir des mêmes prix, juste avec des formules différentes (différences de lissage, de périodes, etc.). Donc, leurs prédictions suivent des tendances très proches, et donc leurs corrélations avec les valeurs réelles sont similaires.

Le close est une valeur absolue du prix, alors que les stochastiques sont des indicateurs normalisés entre 0 et 100. Les stochastiques sont des indicateurs de momentum et tendance, donc les prédictions les suivent mieux sur des petites fenêtres. Le close absolu est beaucoup plus volatile et peut avoir des décalages dans le temps, et donc des corrélations plus dispersées.

Pour les tendances, nous avons des résultats autour de 50%, ce qui nous montre une prédiction assez hasardeuse. Voici le pourcentage de bonnes tendances sur 15 points, et point par point pour chaque variable :

Variables	tendance point par point	tendance sur 15 points
Stochastique RL	44,66%	48,77%
Stochastique %D	45,91%	50,09%
Stochastique %K	45,86%	49,97%
Close	46,50%	50,35%

On voit cependant que les résultats sont plus satisfaisants sur 15 points.

3.2.3. Analyse des résultats

L'analyse croisée des métriques et des sorties graphiques permet de tirer plusieurs conclusions sur la capacité prédictive de TimeGrad dans un contexte de marché volatil :

- Visuellement, le modèle parvient régulièrement à reproduire la "morphologie" des courbes, notamment pour nos stochastiques de momentum, comme l'illustre le graphe ci-dessous. Les trajectoires générées ne sont pas de simples droites mais conservent une courbure crédible. Toutefois, cette fidélité visuelle ne se traduit pas systématiquement par une exactitude temporelle : on observe souvent un léger déphasage entre la montée prédite et la réalité, un phénomène classique en prédiction de séries financières où le modèle anticipe ou réagit avec un retard aux micro-variations.




Figure 9 : Graphique de 5 prédictions de Stoch %D sur des fenêtres temporelles entrecoupées

- L'étude des distributions de corrélation (Figure 8) révèle une dichotomie nette entre les variables :
 - Le prix (Close) : La distribution de corrélation suit une forme de courbe gaussienne centrée. Cela indique que les prédictions sont sans corrélation avec les vrais valeurs.
 - Les indicateurs stochastiques (RL, %D, %K) : à l'inverse de celle du close, ces distributions présentent un profil constant, légèrement "en cuvette". Cette forme suggère que la corrélation est chaotique, tantôt

positive tantôt négative, sans semblant de de tendance, la corrélation ne nous indique rien sur les données prédites par rapport aux données réelles, si ce n'est qu'elles sont sans lien. Cela s'explique par la nature même des stochastiques : ce sont des oscillateurs bornés (0-100) extrêmement sensibles au bruit. Un léger écart de prédiction peut entraîner une inversion brutale de l'indicateur stochastique, brisant instantanément la corrélation.

- Les scores de tendance oscillant autour de 50 % (48,77 % pour le RL et 50,09 % pour le %D) confirment la difficulté du modèle à surpasser le hasard sur un horizon de 15 points. En finance, ce seuil de 50 % est une barrière critique. Nos résultats montrent que si TimeGrad est performant pour générer des enveloppes de probabilités (intervalles de confiance), il peine à s'extraire de l'aspect chaotique du marché.

Toutefois, la calibration observée précédemment, où la réalité s'inscrit dans l'intervalle à 50 % environ la moitié du temps, prouve que le modèle n'hallucine pas sur son incertitude. Il ne prédit pas la vérité avec certitude, mais il quantifie correctement son ignorance, ce qui reste une avancée majeure pour ce projet.

4. Difficultés rencontrées et perspectives d'évolution

Deux grandes sources de difficultés principales sont à relever dans le cadre de ce projet :

- L'environnement de travail et le code source. En effet, dans le cadre de ce travail, il n'était pas question de construire des modèles manuellement mais d'en adapter des existants. Les recherches ont pris plusieurs mois entre les difficultés à installer les environnements virtuels et dépendances de chaque projet, des problèmes de compatibilité de version, compatibilité des pilotes du GPU avec les différentes technologies, entre autres. Partie installation et mise en place à part, il fallait prendre en main plusieurs modèles tester, les modifier pour les adapter à notre cas d'étude, abandonner un projet, en retrouver un autre, etc.. Cette phase de recherche de support de travail a été la plus conséquente et chronophage.
- L'étude des données. Avant de recevoir par L. Chateau un large dataset de valeurs boursières, nous étions cantonnés à des petits dataset obtensibles via call API d'une longueur de 3000 unité temporelles maximum, avec des valeurs à retravailler parfois, la phase de traitement et obtention des données fut la seconde difficulté de ce projet. De plus, en ayant directement la valeur d'une stochastique, il peut être ardu d'en retrouver la formule.

Malgré ces difficultés, et à l'aide des résultats obtenus précédemment, la piste des modèles de diffusion dans le cadre de la prédiction de séries temporelles financières reste prometteuse de par sa capacité à identifier des motifs mais reste inefficace seul. En couplant un modèle de diffusion à un modèle de régression apprenant de manière plus précise les comportements génériques, grossiers, des cours, les modèles de diffusion pourraient se révéler pertinents afin d'affiner ces résultats, d'apprendre les comportements fin, motifs plus abstraits de ces objets. En modifiant le bruitage d'entrée du modèle, en y appliquant des bruits suivant des lois de Lévy, ayant des queues épaisses pour les valeurs extrêmes. Cela permettrait de rendre

plausible pour le modèle l'hypothèse d'un krach, comportement forcément écarté par les bruits gaussiens, limitant l'impact des comportements extrêmes.

Conclusion

Ce projet nous a permis d'explorer la complexité de la prédiction financière à travers le prisme novateur des modèles de diffusion. Si le parcours a été marqué par l'échec de plusieurs architectures (Kronos, TimeDiffusion), l'implémentation du modèle TimeGrad a constitué un tournant décisif, nous permettant de passer de prédictions déterministes à une approche probabiliste, en multivarié qui plus est.

Toutefois, les résultats obtenus nuancent les résultats impressionnants (visuellement seulement) des prédictions. Avec une précision sur la tendance globale stabilisée autour de 50 % et des corrélations moyennes proches de zéro pour le cours du Bitcoin, le modèle semble, en l'état, se heurter à l'efficacité des marchés : à court terme ($T+15$), le signal prédictif reste masqué par un bruit stochastique dominant. Ce score, bien qu'en apparence modeste, n'enlève rien à la valeur technique de l'étude. Il démontre que si TimeGrad est capable de générer des trajectoires réalistes (comportements des courbes, respect de la volatilité), il ne peut à lui seul résoudre l'incertitude fondamentale des prix sans informations complémentaires.

Le parcours de ce projet a mis en évidence plusieurs enseignements fondamentaux :

1. La supériorité du probabiliste : malgré une précision directionnelle incertaine, la capacité de TimeGrad à quantifier son ignorance via des intervalles de confiance est un atout majeur par rapport aux autres modèles.
2. L'importance du calibrage : nous avons démontré que la performance d'un réseau de diffusion dépend d'un équilibre fragile entre la complexité de l'architecture (128 neurones sur 3 couches) et la gestion de la convergence pour éviter le surapprentissage.
3. La limite de l'univarié pur : l'intégration des stochastiques (%K, %D, RL) a été indispensable, mais elle souligne que le prix seul n'est pas suffisant pour casser la barrière statistique du hasard et que de multiples facteurs entrent en jeu.

En perspective, ce travail pose les jalons d'un système plus robuste. Pour dépasser le seuil de 50 %, il serait pertinent d'intégrer des données exogènes (volumes, indicateurs supplémentaires) et d'explorer, comme évoqué en ouverture, des bruits de diffusion non-gaussiens (Lois de Lévy) mieux adaptés aux "krachs" financiers.

En conclusion, ce projet aura été une immersion concrète dans la recherche en Deep Learning. Si les modèles de diffusion étudiés ne permettent pas encore prédire l'avenir avec certitude, ils offrent un cadre scientifique puissant et encourageant pour modéliser le risque, transformant une prédiction binaire en un véritable outil d'aide à la décision probabiliste.

Bibliographie

Modèles :

Unconditional time series diffusion :

<https://github.com/amazon-science/unconditional-time-series-diffusion>

TimeDiffusion : <https://github.com/timetoai/timediffusion>

TimeGrad : <https://github.com/Zjh152/TimeGrad>

Kronos : <https://github.com/shiyu-coder/Kronos>

Article à propos de TimeGrad : <https://icml.cc/virtual/2021/poster/8591>